# Cryptologie 2 (MU5IN951) : Examen Réparti 2

durée 2h00 / 2 pages

6 février 2025

Documents autorisées. L'utilisation de tout matériel électronique (en dehors d'une montre non connectée) est interdite. Il y a deux parties indépendantes.

Une rédaction claire et concise sera appréciée. **Toute affirmation devra être justifiée.** Une question non résolue n'empêche pas de faire les suivantes. (dans ce cas indiquez clairement que vous admettez le(s) résultat(s) de la question non faite).

## 1 Une mauvaise fonction à sens unique

Soit $p$ un nombre premier (d'au moins 128 bits). On considère la fonction :

$$f : \begin{array}{ccc} \mathbb{Z}_p & \longrightarrow & \mathbb{Z}_{p^2} \\ x & \mapsto & \begin{cases} 0 & \text{si } x = 0 \\ \left\lfloor \frac{x^{-1} \bmod p^3}{p} \right\rfloor & \text{sinon} \end{cases} \end{array}$$

Qui est évaluée par le petit bout de code suivant :

```
def f(x):
    if x == 0:
        return 0
    return invmod(x, p**3) // p
```

La fonction `invmod(a, q)` renvoie l'inverse modulaire de $a$ modulo $q$ (et déclenche une exception si le calcul est impossible).

Le but de cet exercice est de montrer que cette fonction n'est pas à sens unique.

**Question 1 :** Montrez que si $y = f(x)$, alors il existe deux entiers $a, b$ tels que $pxy + ax = 1 + bp^3$. Dans quels intervalles $a$ et $b$ sont-ils confinés ?

**Question 2 :** L'équation précédente n'est pas linéaire (à cause du produit $ax$). Mais on peut s'en sortir en la linéarisant : montrez que si $y = f(x)$, alors $pxy - bp^3$ est « petit » (dans un sens que vous définirez).

On considère le réseau engendré par les lignes de la matrice :

$$M = \begin{pmatrix} p & py \\ 0 & p^3 \end{pmatrix}$$

**Question 3 :** Montrez que trouver le vecteur le plus court de ce réseau permet d'inverser efficacement la fonction.

**Question 4 :** [question bonus assez difficile] Si la fonction calculait `invmod(x, p) // q`, quelle relation est-ce que $p$ et $q$ doivent entretenir pour que l'attaque continue à marcher ?

## 2 Crypto Dark Matter

Cet exercice est librement inspiré par l'article *Exploring Crypto Dark Matter : New Simple PRF Candidates and Their Applications* publié en 2018 au colloque « Theory of Cryptography Conference (TCC) » par Dan Boneh, Yuval Ishai, Alain Passelègue, Amit Sahai, et David J. Wu.

On considère deux entiers $a, b$ aléatoires modulo un nombre premier $p$, ainsi qu'un entier $q < p$.

$$\mathcal{F}_{a,b} : \begin{array}{ccc} \mathbb{Z}_p & \longrightarrow & \mathbb{Z}_q \\ x & \mapsto & ((ax + b) \bmod p) \bmod q \end{array}$$

Autrement dit, on calcule une fonction affine modulo $p$, puis on réduit le résultat modulo $q$. La « clef » de la PRF (qui est secrète) est $(a, b)$.

**Question 5 :** Montrez que si on connaissait $a$ mais pas $b$, alors on pourrait malgré tout « prédire » la valeur de $\mathcal{F}_{a,b}(x)$ avec une bonne probabilité.

**Question 6 :** Quelle doivent être les tailles de $p$ et $q$ pour empêcher des attaques naïve par recherche exhaustive ?

**Question 7 :** Supposons qu'un algorithme qui peut évaluer la fonction parvienne à calculer $a$. Montrez que la fonction n'est pas une PRF sûre.

On va voir qu'un tel algorithme existe dans certains cas (ceci permet alors « prédire » la fonction avec bonne probabilité, et donc cela montre que ce n'est pas une bonne PRF). Pour cela, on suppose qu'on connaît $n$ couples $(x_1, y_1), \ldots, (x_n, y_n)$ avec $y_i = \mathcal{F}_{a,b}(x_i)$, pour des $x_i$ quelconques (par exemple, aléatoires). On suppose aussi qu'on connaît $\mathcal{F}_{a,b}(0)$.

**Question 8 :** Quelle est le nombre minimum d'échantillon (c.a.d. la valeur de $n$) qui puisse permettre de retrouver $a$ (même avec une puissance de calcul illimitée) ?

**Question 9 :** Montrez que si $y_i = \mathcal{F}_{a,b}(x_i)$, alors il existe deux entiers $u_i, v_i$ tels que $ax_i + b + u_i p + v_i q = y_i$. Dans quels intervalles vivent $u_i$ et $v_i$ ?

Soit $\lambda$ un entier (qu'on fixera plus tard). On considère le réseau engendré par les lignes de la matrice :

$$B = \left(\begin{array}{ccc|ccc|c} \lambda p & & & & & & \\ & \ddots & & & & & \\ & & \lambda p & & & & \\ \hline \lambda q & & & q & & & \\ & \ddots & & & \ddots & & \\ & & \lambda q & & & q & \\ \hline \lambda x_1 & \ldots & \lambda x_n & & & & 1 \end{array}\right)$$

À chaque fois les $\cdots$ remplacent $n-2$ coefficients. La matrice est de taille $2n+1$.

**Question 10 :** Notons le produit matrice-vecteur : $z := \left(\begin{array}{ccc|ccc|c} u_1 & \ldots & u_n & v_1 & \ldots & v_n & a \end{array}\right) \times B$. Que vaut $z$ ? Pourquoi serait-il intéressant de connaître $z$ ?

**Question 11 :** On ne connaît pas $z$ mais on peut connaître un vecteur $t$ qui en est « proche » (en distance euclidienne). Quel est $t$, et quelle est sa distance à $z$ ?

L'idée c'est que chercher un vecteur proche de $t$ dans le réseau engendré les lignes de $B$ va révéler $z$ si les bonnes circonstances sont réunies.

**Question 12 :** Quel est le volume du réseau engendré par les lignes de $B$ ? Que prédit l'heuristique gaussienne pour la norme de son vecteur le plus court ?

Le problème c'est que ce réseau contient un vecteur « anormalement court ».

**Question 13 :** Montrez que le vecteur $v = (0, \ldots, 0, p)$ appartient au réseau engendré par les lignes de $B$ (remarquez qu'il peut être plus court que ce que prédit l'heuristique gaussienne, et que sa longueur est indépendante de $\lambda$).

On va faire l'hypothèse que c'est le vecteur le plus court du réseau (sa norme est $\lambda_1 = p$), et que l'heuristique gaussienne « prédit » la norme $\lambda_2$ du *deuxième minimum* du réseau (c.a.d. du vecteur le plus court qui n'est pas un multiple de $v$). Cette hypothèse est (empiriquement) bien vérifiée, en tout cas tant que $n$ est assez grand et que $q$ n'est pas trop petit.

**Question 14 :** Justifiez que si $\|t - z\| \leq \frac{1}{2}\lambda_2$, alors le vecteur du réseau le plus proche de $t$ est de la forme $z + kv$ pour un certain entier $k$ (ne pas hésiter à faire un schéma en 2 dimensions). Expliquez pourquoi connaître ce vecteur permet de casser la PRF.

**Question 15 :** Expliquez comment choisir la valeur de $\lambda$ pour que la condition $\|t - z\| \leq \frac{1}{2}\lambda_2$ soit satisfaite.

**Question 16 :** Pour conclure, décrivez un algorithme capable de distinguer la PRF d'une fonction aléatoire.

Pour étudier les choses plus en profondeur, il faudrait vérifier à quelle(s) condition(s) est-ce que l'hypothèse qu'on a faite est bien vérifiée.

# Correction

**1** Vu la vision par $p$, il existe un quotient $y$ (c'est la sortie) et un reste $a$ tel que `invmod(x, p**3)` $= yp + a$. Comme c'est le reste de la division par $p$, on a que $0 \leq a < p$.

Vu ce que calcule la fonction "invmod", on a $x$`invmod(x, p**3)` $\equiv 1 \bmod p^3$, donc il existe un entier $b$ tel que $x$`invmod(x, p**3)` $= 1 + bp^3$. Comme $0 \leq x < p$, on trouve que $0 \leq b < p$.

En mettant tout bout-à-bout, on arrive à $x(yp + a) = 1 + bp^3$ et c'était ce qui était demandé.

**2** Le produit $ax$ est dans l'intervalle $[0, p^2[$. Donc on a forcément $pxy - bp^3 = 1 - ax$. Or $y$ est de taille $\approx p^2$ tandis que $x$ est de taille $\approx p$. Donc $pxy \approx p^4$ et $bp^3$ est aussi de taille $\approx p^4$. Mais la somme des deux est de taille $\approx p^2$, ce qui est "anormalement" faible.

**3** Déjà, comme c'est un réseau de dimension 2, LLL renvoie prouvablement le vecteur le plus court. Ensuite, le volume du réseau est $p^4$ et donc le vecteur le plus court est de norme inférieure à $\sqrt{2}p^2$.

Le vecteur $(x, -b)B = (xp, pxy - bp3)$ est de norme $\leq \sqrt{2}p^2$, donc c'est un bon candidat à être le plus court (arnaque : il faudrait "prouver" qu'il n'y en a pas d'autre plus court). On va admettre que c'est bien lui le plus court. En vrai, il faudrait montrer qu'il ne peut pas y en avoir beaucoup de norme faible et qu'on peut tous les énumérer efficacement, donc qu'on dispose d'un moyen fiable de trouver celui-là rapidement, mais c'est nettement plus compliqué...

Mais en tout cas, on peut construire la matrice $M$ à partir de $y = f(x)$, et ce vecteur court révèle $x$ !=

**5** En évaluant $\mathcal{F}(0)$ on apprend $b \bmod q$. Donc on sait que $b = \mathcal{F}(0) + \ell q$ pour un certain $\ell$. L'idée ensuite, c'est de supposer que $(ax + b \bmod p) \bmod q \approx (ax \bmod p) + \mathcal{F}(0) \bmod q$.

Quand on calcule $\mathcal{F}(x)$, que se passe-t-il ? Il existe un entier $k$ tel que $ax = kp + r$ avec $0 \leq r < p$. Il existe un AUTRE entier $k'$ tel que $ax + b = k'p + r'$ avec $0 \leq r < p$. Et vu la taille de $b$, ou bien $k' = k$, ou bien $k' = k + 1$.

Et $k$, on peut le calculer nous-même vu qu'on possède $a$.

Donc ou bien $\mathcal{F}(x) = (ax + b - kp) \bmod q$ ou bien $\mathcal{F}(x) = (ax + b - (k + 1)p) \bmod q$.

Et donc ou bien $\mathcal{F}(x) = (ax - kp) + \mathcal{F}(0) \bmod q$ ou bien $\mathcal{F}(x) = (ax - (k + 1)p) + \mathcal{F}(0) \bmod q$.

Donc on peut prédire la valeur de $\mathcal{F}(x)$ en se trompant avec probabilité seulement $1/2$.

**6** Pour que la fonction soit à sens-unique, il faut que sa sortie (donc $q$) fasse au moins 128 bits (en 2025).

Après, on peut apprendre facilement $b \bmod q$ en calculant $\mathcal{F}(0)$ et $a \bmod q$ en calculant $\mathcal{F}(1) - \mathcal{F}(0)$. Il faut donc que la partie "cachée" de $a$ soit suffisamment grande pour qu'on ne puisse pas la retrouver par recherche exhaustive. Ceci suggère que $p$ doit faire 128 bits de plus que $q$.

**7** Le problème consiste à déterminer si une boite noire contient $\mathcal{F}_{a,b}$ ou bien une fonction aléatoire.

Voici un distingueur : obtenir $a$ (avec l'algo fourni). Obtenir $b \bmod q$ en évaluant la fonction sur 0. Choisir un $x$ aléatoire modulo $p$ puis évaluer la fonction sur $x$ ($y := \mathcal{F}(x)$). Calculer la division euclidienne de $ax$ par $p$ ($ax = kp + r$ avec $0 \leq r < p$). Si $y = (ax - kp) + \mathcal{F}(0) \bmod q$ ou bien $y = (ax - (k + 1)p) + \mathcal{F}(0) \bmod q$, alors renvoyer "PRF". Sinon renvoyer "fonction aléatoire".

Quand il a affaire à la PRF, cet algorithme la reconnaît systématiquement. Il pourrait répondre "PRF" par erreur sur une fonction aléatoire avec probabilité $2/p$.

**8** Chaque sortie est de taille $\log_2 q$ (en bits) et on cherche à retrouver $\log_2 p$ bits d'information (c'est la taille de $a$). Donc a priori il faut au moins $log_2 p / \log_2 q$ sorties.

**9** En fait on a déjà fait le raisonnement un peu avant. Posons la division euclidienne de $ax_i + b$ par $p$ : $ax_i + b = u_i p + r_i$ avec $0 \leq r_i < p$. $ax_i + b$ est plus petit que $(p - 1)^2 + p = p^2 - p + 1 < p^2$. Donc $u_i$ est forcément strictement inférieur à $p$.

Ensuite posons la division euclidienne de $r_i$ par $q$ : $r_i = v_i q + y_i$ avec $0 \leq y_i < q$ (c'est la sortie de la fonction). Comme $r_i$ est plus petit que $p$, alors $v_i$ est plus petit que $p/q$.

**10** On obtient :

$$z = \left( \begin{array}{ccc|ccc|c} \lambda(y_1 - b) & \dots & \lambda(y_n - b) & qv_1 & \dots & qv_n & a \end{array} \right)$$

Donc en particulier on apprend $a$ dans la dernière coordonnée...

**11** On connaît :

$$t = \left( \begin{array}{ccc|ccc|cc} \lambda(y_1 - \mathcal{F}_{a,b}(0)) & \dots & \lambda(y_n - \mathcal{F}_{a,b}(0)) & 0 & \dots & 0 & 0 & 0 \end{array} \right)$$

Et sa distance avec $z$ est :

$$\|t - z\| \leq p\sqrt{n+1}$$

**12** $V = \lambda^n p^n q^n$. Donc $\lambda_1 \approx \sqrt{2n+1}(\lambda pq)^{n/(2n+2)} \approx \sqrt{2n+2}\sqrt{\lambda pq}$.

**13** C'est $(-1, \dots, -1, 0, \dots, 0, 0, p)B$. Il est de norme $p$.

**14** Quels sont les vecteurs proches de $z$ dans le réseau ? Il y a $z + kv$ qui est à distance $|k|p$. Mais en dehors de ceux-là, tous les autres sont à distance au moins $\lambda_2$ par définition de $\lambda_2$. Donc un point du réseau à distance inférieure à $\lambda_2/2$ de $t$ est forcément l'un des $z + kv$.

La dernière coordonnée de $z + kv$ est $a + kp$, mais il suffit de la réduire modulo $p$ pour retrouver $a$.

**15** La condition souhaitée est réalisé si $p\sqrt{n+1} \leq 0.5\sqrt{2n+2}(\lambda pq)^{n/(2n+2)}$. Il nous faut simplifier ceci :

$$\begin{aligned} p\sqrt{n+1} &\leq 0.5\sqrt{2n+1}(\lambda pq)^{n/(2n+1)} \\ 2p\sqrt{n+1} &\leq \sqrt{n+1}(\lambda pq)^{n/(2n+1)} \\ p(2p)^n &\leq (\lambda q)^n \end{aligned}$$

Lorsque $n$ est grand, cette condition sera satisfaite si $\lambda q$ est nettement plus grand que $2p$, autrement dit si $\lambda$ est nettement plus grand que $2p/q$.

Mais la condition sera satisfaite pour tout $n \geq 1$ si $\lambda$ est nettement plus grand que $2p^2\sqrt{2}/q$.

**16** Calculer $n$, Écrire la base du réseau, résoudre CVP, retrouver $a$, faire le truc de la question d'avant pour distinguer.